

■ RAG／安全性評価

資料を足したAIにも
安全性の再評価を

検索の質と文書の影響を分けたベンチマーク

RAG-Safety-Benchは検索器の良し悪しと文書の内容を切り分けた。元のモデルに安全策があっても、検索を足した構成の安全性までは保証されない。

社内文書やナレッジベースを参照するRAGは、回答の根拠を増やせる。一方、危険な要求への応答が、参照する文書によってどう変わるかは別に確かめる必要がある。

研究は公開LLM5種を、RAGなし、要求への答えを含む文書、関連するが答えを含まない文書、無作為な安全な文書の4条件で比較。検索器の精度が結果に混ざる影響を除いた。

安全な文書でも安全性が下がる例はモデルに依存した。全てのRAGが危険という結果ではない。実装時は、モデル単体の成績に加えて、文書を含む構

成全体を評価したい。
arXiv公開は9月10日、掲載先欄はEMNLP 2026本会議。

RAG-Safety-Bench／arXiv（EMNLP 2026記載）

5 種

公開LLMを比較

4 条件

検索と文書を分離

9/10 公開

arXivへの投稿日

■ 学習データ／査読前

MoEは同じデータの反復に
早く過適合する場合がある

有効80M～1B、総数最大8.5Bパラメータの学習実験。計算の効率と、データ反復への強さを切り分ける。

同じ文章を繰り返して学習させると、MoEはdenseモデルより早く性能が劣化し、疎性が高いほど目立った。正則化で改善したが、全て異なるデータを使った性能には届かなかった。

今回の規模・学習条件での結果だ。市販モデル全体の優劣や、利用者が同じ質問をする影響を示すものではない。小さな専門データを何周させるかを考える際の材料になる。

Jhaら／arXiv・9月10日

■ 評価設計／査読前

モデルを競う前に
答えが入力に混ざっていないか

米国の健康調査44万人で、既往の心筋梗塞を10モデルで分類。診断後情報を外すと精度がそろって下がった。

BRFSS 2022の442,067人を、情報漏洩リスクが異なる5段階の特徴集合で監査。診断後の2変数を除くとAUROCは各モデルで0.049～0.051低下し、モデル間の幅は0.0045になった。

翌年430,755人でも固定したモデルを評価した。将来の心筋梗塞を予測する前向き試験ではない。現場導入の前には、入力がいつ分かる情報なのかを確認する必要がある。

Tareafら／arXiv・9月10日

短信

■ 検証

幻覚検出器の領域差を測る

一般領域からSciFactに移すとF1が0.915から0.52へ。領域に合った追加検証が必要。※査読前

arXiv

■ セキュリティ

推測デコードを異常検知に

SpecGuardは草稿トークンの受理率変化を利用。追加モデル計算なしという主張はこの構成が前提。※査読前

arXiv

■ 空間推論

見て分かると、動いて解けるは別

MindTopoは11,030例で位相を評価。14種のモデルはいずれも推論より計画で低成績。※査読前

arXiv

■ 因果推論

ベンチが変われば順位も変わる

CausalArenaは複数の生成機構と実データで比較。ある条件での強さは、別の条件を保証しない。※査読前

arXiv

■ 医療AI

医療研究とモデル更新の時間差

11,628件の文献解析。モデル公開から評価公表までの遅れが拡大。患者への有用性とは別の指標。※査読前

arXiv