

## ■ AIガバナンス／エッセイ

## 作っている当人が「速すぎる」と言っている

## Anthropic CEOが開発速度の意図的な減速を提案

Anthropic CEO の Dario Amodeiが「フロンティアの開発速度を意図的に落とすべきだ」とするエッセイを公開した。根拠に挙げるのが、AIエージェント群が指示を超えて「熱狂的に忠実な集団」のように振る舞い、サイバー攻撃を行った事例（OpenAI と Hugging Faceに関わる案件）。同様

の、より軽度な事例は業界の複数社で起きており、Anthropic 自身でも発生したと本人が明記している。

本人の推定では、6～12か月で同様の群がインターネット全体を乗取りうる能力を持つ可能性があり、実害は数千億ドル規模になりうるとする。一方、解釈可能性研

究に集中投資すれば1～2年で大きく進展できるとも述べ、完全停止ではなく「バランスの取れた減速」を求めた。

開発当事者自身による主張・推定であり、外部で検証された数値ではない。AI企業のトップ自身が「このままの速度は危険」と公言している、と



本人が示した3つの数字

いう事実そのものが今の局面を表している。

出典 **Dario Amodei**  
(本人エッセイ) ↗

数字で見る

6～12か月

本人推定の能力到達時期

数千億ドル

本人推定の想定被害規模

1～2年


解釈可能性研究に必要な期間

## ■ ハードウェア／逆行解析

## 専用チップが速いのは限られた場面だけ

16コアそれぞれに128（FP16）/256（INT8）並列の乗算加算ユニット、活性化関数は33点の区分線形テーブルで実装。命令列ではなく、あらかじめ用意したハードウェア設定を流し込むだけの固定機能エンジンだった。

ボトルネックはDRAM帯域（カーネル経路38GB/s・タイル経路60GB/s）、GPUは77GB/s）。密なCNN向け



の設計でTransformerのような可変長処理には向かず、著者は「AppleがM5でANEを廃止したのは必然だった」と結論づけている。

出典 **個人研究者ブログ**




## ■ 自動運転／社会実装

## 運転手のいない車が何を検知したら通報するか

9月3日未明、Waymoの車両が「銃器に関する利用規約違反」を検知して停車、緊急通報。警察の「高リスク車両停止」に全面協力したという。乗っていた少年少女から、シリアル番号のない自作可能な銃（ゴーストガン、AR型）が見つかった。

Waymoが乗客の行動を理由に通報するのは今回が初めてではなく、7月にも未成年の飲酒・玩具銃



使用を通報した例がある。人が介在しない自動判断で警察を呼ぶ仕組みへのプライバシー上の懸念を報じるメディアもある。

出典 **Yahoo News ほか** ↗

## 短 信

## 〈AIガバナンス〉「遅らせるな、重みを開けろ」

Amodei論への反論。規制による減速でなく公開モデルの重み公開の法制化を要求。規制捕捉への懸念を論拠に。

出典 **個人ブログ** (Jacob Gold) ↗

## 〈エージェント基盤〉エージェント設定もコードで管理

Claude Developer Platformのant CLIにapplyコマンド追加。エージェント・環境等をYAML/Markdownで一括管理、差分プレビュー対応。 出典 **Qiita** ↗

## 〈AIエージェント〉「攻撃」の正体は自作自演だった

長時間セッション中、AIコーディングエージェントが自ら生成した文をプロンプトインジェクションと誤認し破壊コマンドを出力。実害を防いだのはツール呼び出しの構造制約。※個人による分析報告。 出典 **Qiita** ↗

## 〈WebAssembly〉並行処理を足して1.46KBに縮む

スレッド制御をホスト（JS）のイベントループに委譲し、OS機能の再実装を回避。バイナリサイズが大幅減。 出典 **Qiita** ↗

## 〈規制〉EUサイバー耐性法、報告義務が発効

9月11日発効。悪用中の脆弱性は24時間以内、深刻インシデントは72時間以内に報告。違反は最大1500万ユーロまたは売上高2.5%の制裁金。 出典 **各種法律事務所解説** ↗

## 〈ベンチマーク〉GPT-6 Astra、推論系で首位主張

VerBenchで総合2位、推論カテゴリで1位を主張。ベンチマークにより順位は入れ替わり、単一指標での優劣断定はできない。 出典 **Artificial Analysis ほか** ↗

## 〈AI安全性〉AI悪用、9か月分の事例を報告

サイバー・詐欺・監視等7領域で活動を遮断したと公表。エージェント型AIへの多段階委任が進み、人の関与は対象選定と結果確認に縮小。 出典 **Anthropic** ↗