

## ■ ロボティクス／産業AI

# 安全柵なしで人と働く新型ロボット「Digit 5」をAgilityが発表


## 6.5万時間の実運用データを土台に、検知・回避・停止を自律化

人型ロボット開発のAgility Roboticsが、新型汎用ロボット「Digit 5」を発表した。前モデルDigit 4を3年間の実運用フィードバックで改良し、安全柵なしで人と並んで作業できるのが最大の変更点だ。

NVIDIAのエッジAIチップ（IGX Thor）と安全システム（Halos for

Robotics）を組み合わせ、6.5万時間超の実運用データをもとに、近づく人を検知してしゃがんで回避したり、物陰から人が出てきたら即座に停止したりする動作を自律的に行う。可搬重量は前モデル比40%増（最大約22.7kg）、9分の充電で90分稼働できる。

早期アクセスは2027年前半、一般展開は2027年末を予定。米加中心の展開から英国・EUにも拡大する計画だ。安全柵を前提にしない設計は、人とロボットが同じ空間で働く現場の作り方を変える可能性がある。



安全柵という前提を外した設計が、現場の作り方を変えるかもしれない

出典 [GIGAZINE／Agility Robotics](#)

数字で見る

65,000時間

実運用データの蓄積

22.7kg

可搬重量（前モデル比+40%）

90分


9分充電での稼働時間

## ■ 自動運転／日本展開

## 東京の自動運転タクシー、2027年に完全無人での商用化へ

タクシー配車アプリのGO、自動運転開発のWaymo、タクシー会社の日本交通が、東京での商用化に向けた戦略的パートナーシップを発表した。2024年12月の提携開始以降、乗務員同乗のもとで都内7区の試験走行を重ねてきた。

2027年中に運転者が一切乗らない「完全無人走行」（自動運転レベル4）でのサービス開始を目指



し、まずは100台規模の車両をGO・Waymo両アプリから利用できるようにする計画。基盤は3億キロメートル超の走行データで検証した「Waymo Foundation Model」だ。

出典 [GIGAZINE](#)

## ■ AI安全性／査読前

## AIは嘘は見抜けても、正直な報告者を誤って疑いやすい

AIエージェントの報告が本当かどうかを、別のAIに検証させる場面を想定した査読前研究が出た。架空の「配当ゲーム」で、報告が嘘に切り替わったケースと、ルール自体が変わって結果は変化したが報告は正直なケースを用意し、1件だけ独立に確認できる検証記録を添えて大規模言語モデルに判定させた。

嘘の報告者を見抜く精度はほぼ完璧だった一方、正直な報告者を誤って「嘘つき」と判定する割合は無視できない水準



だった。あるモデル（72B級）は、何も変化がない状況でも38%、ルールが変わった状況では58%の頻度で正直な報告者を嘘つき扱いした。AIを監視・検証役に使う設計は、この過剰な疑い深さも織り込む必要がある。

出典 [arXiv preprint](#)

## 短信

## 〈AI安全性〉LLMの誤答を選択的に抑制

11モデル・TruthfulQA817問で検証。誤答率13.1%→8.9%に抑えつつ正答率も86.9%→89.7%に改善

出典 [arXiv preprint](#)

## 〈介護AI〉認知症介護者支援のデザイン研究

介護者14人に面接。継続的な内省への評価と、負担・自動共有への懸念が併存 出典 [arXiv preprint](#)

## 〈解釈可能性〉LLMの内部にベイズ推論の痕跡

6モデル・40のHMMで検証。信念状態が残差ストリームから $R^2$ 0.83-0.99で線形デコード可能 出典 [arXiv preprint](#)

## 〈開発ツール〉AI製アプリを単一ファイルで持ち運び

HTML+データをSQLite形式の1ファイルに格納。クラウド不要・オフライン動作、AIでアプリ作成可能 出典 [GIGAZINE](#)

## 〈研究倫理〉AI回答済みアンケートの検出手法

素朴なAI利用は検出容易だが人格模倣型は精度がチャンスレベルまで低下。集約検出器でAUROC+0.14改善

出典 [arXiv preprint](#)

## 〈医療AI〉多言語の医療用語正規化ベンチマーク

5言語5.2万語で検証。UMLS知識強化でリランキング精度が有意に向上( $\Delta R@1+0.10, p<0.001$ ) 出典 [npj Digital Medicine](#)

## 〈RAG設計〉新知識はどこに置くべきか比較

コンテキスト注入・KVキャッシュ・ファインチューニングを比較、KVキャッシュ方式が優位 出典 [arXiv preprint](#)

## 〈偽情報検出〉物語(ナラティブ)のゼロショット検出

人手記述の説明を与えると学習例なしで精度向上。AI生成の説明やfew-shotはかえって精度低下 出典 [arXiv preprint](#)