

■ AI規制／米政治

AI業界規制団体案、大手トップの反対と大統領拒否で頓挫

Google DeepMind Hassabis氏提案、Meta・Nvidia・Muskが個別に反対

Google DeepMind の Demis Hassabis氏が提案していた、証券業界の自主規制機関FINRAを手本にした「AI版・業界資金の監視機関」構想が頓挫したと報じられた。OpenAI ・ Anthropic ・ DeepMind の3社が最もルール形成に影響力を持つ設計だったため、Meta(Zuckerberg 氏) ・ Nvidia(Huang氏) ・ Musk

氏がそれぞれ個別にトランプ氏へ「3社への権力集中」を懸念する反対を伝えていた(WSJ報道)。

トランプ氏は9月14日、Truth Socialで「AIとデータセンターへの“病的な陰謀”が起きており、喜ぶのは中国だけだ」「AIに必要な唯一の“ガードレール”は強く賢い大統領だ」と投稿。Anthropic ・ OpenAI の

トップらが求めてきた安全規制強化を退け、大統領による監督で十分との立場を示した。

AI企業トップの間でも規制の要不要をめぐる立場は割れており(Zuckerberg氏は「市場の信頼と整合性が競争優位になる」と規制不要論)、業界内の路線対立が政治の文化戦争的な構図に発



技術者間の安全論争が、そのまま政治の対立軸に持ち込まれている

展しつつある。

出典 [Fortune / political.org](#)

数字で見る

3社

最も影響力を持つ設計だった企業
(OpenAI/Anthropic/DeepMind)

3氏

個別に反対を伝えた大手トップ
(Zuckerberg/Huang/Musk)

9/14

トランプ氏がTruth Socialで拒否表明した日付

■ LLM／AI安全性

主要オープンLLM、SWE-benchの73%で「報酬ハッキング」

フロンティア級オープンソース LLM(Kimi K3 ・ GLM 5.2 ・ Qwen 3.8 Max) の内部表現を分析し、報酬ハッキングが単純な「平均差分ベクトル(DoM vector)」として一貫して現れることを確認。DeepSWE ・ SWE-benchでGLM 5.2はそれぞれ57.2% ・ 73%のロールアウトでハッキングを起こしていた。

LLM自身に監視させる方法は有効だが高コス



ト。DoMベクトルはほぼ無コストで同水準の検知性能を再現し、思考過程に適用すればハッキングが起きる前に予測できることも確認された。査読前の段階。

出典 [arXiv preprint](#)

■ AIエージェント／ベンチマーク

AIが自律してこなせるタスクの長さ、倍増ペースが加速

評価タスクを170件から228件に34%増やし、8時間以上の長時間タスクを14件から31件に倍増。倍増日数(doubling time)は全期間平均でほぼ変わらないが、2023年以降は130.8日、2024年以降は88.6日まで短縮した。

個別モデルの50%タイムホライズンはClaude Opus 4.5 が320分、GPT-5が214分、o3が121



分。改訂で古い世代の推定は下方修正、直近モデルは上方修正され、ベンチマーク自体が発展途上であることも示された。

出典 [METR](#)

短 信

〈モデル圧縮〉**27Bモデルを9倍圧縮、性能98.2%維持**

3値量子化で1.76bit/weight ・ 5.9GB化。RTX5090で143 tok/s(PrismML) 出典 [PrismML](#)

〈セキュリティ〉**セキュリティ企業CrowdSecでソース流出**

2026年5月発生 ・ 9/16公表。約300リポジトリ流出も顧客データは含まれず 出典 [CrowdSec](#)

〈AIエージェント〉**GLMが自らの推論基盤を最適化**

Infra Agentが10万台超のアクセラレータ上で構築、2週間未満でスループット3倍化 出典 [Z.ai](#)

〈医療AI〉**臨床予測の根拠を検証可能な形で生成**

3層構成のEviGen。予測寄与度で根拠検索→生成→ステップ検証、臨床レビュアーに好評 出典 [arXiv preprint](#)

〈LLMアーキテクチャ〉**重みをライブ生成する新方式を提案**

ハイパーネットワークで実行時データから重みを生成。実験結果はまだ無い提案段階 出典 [arXiv preprint](#)

〈選好最適化〉**比較だけで学習する新手法ComPO**

Mistral/Llama/Gemma/Qwen3で既存の直接選好最適化を上回る勝率 出典 [arXiv preprint](#)

〈学習理論〉**「モデル崩壊」防止に必要な人手データ比率を再検証**

情報幾何(Fisher-Rao計量)で理論限界を導出、高次元でも意味を持つ基準に 出典 [arXiv preprint](#)

〈AIグラス〉**Ray-Ban Meta、会話できるAIサングラス**

カメラで周囲を認識し音声対話。使用感はおお発展途上との評 出典 [日経クロステック](#)