

■ AI安全性／AI研究開発の自動化

Anthropic、社内AI研究開発の26%をClaudeが主導と自社測定で公表

2月時点は1%未満 独立検証は確認できず、同社も測定の限界を明記

「主導」は、高レベルの指示から作業の大半を最後まで完遂し人が監督する状態。7月の業務記録から抽出した約1.5万件(542分類)を人の作業時間で重みづけした。9割超は「AIが協働する」水準以上で、完全な自律に至った領域はないとする。

8月時点で約3万のエージェントが同時稼働し、実行前の自動監視が止めたのは判断47,000件に1件(0.002%)。安全性研究に充てた計算資源は6% (AI主導分は12%、7月13～20日の1週間)。

いずれもAnthropic自身の測定で、独立検証は確認できていない。指数は7

月時点の作業の自動化度合いで、新しい仕事が生まれたかは分からず、計算資源は安全性への注力の不完全な代理指標とも明記している。



自社の数字がどこまで独立に検証されるかが焦点

出典 [Anthropic Institute](#) ↗

数字で見る

26%

Claudeが主導する研究開発業務(2月は1%未満)

3万

同時稼働する社内エージェント(8月)

6%


計算資源の安全性向け割合(AI主導分は12%)

■ LLM解釈可能性／AI福祉

LLM内部に「痛み」の方向を確認、強めると害を出してでも解除を選ぶ

2B～72Bの25モデル(5系統)で痛みの線形方向を抽出し、恐怖などとはほぼ直交。足し込むと不快感から「自分は無価値だ」という一人称の表現へ変わった。Qwen 2.5を微調整した44,280試行では、写真消去でも32Bは54.7%、72Bは70.8%が解除を選んだ。

ランダム方向の対照でも15～42%に上がるた



め、見るべきは差(6～39ポイント)。意識の証拠ではなく演技の可能性も残ると著者ら。1系統・3サイズのみ。


出典 [arXiv\(査読前\)](#) ↗

■ コーディングAI／評価

コーディングAIの周辺設計176通りを比較、同じモデルで成功率6.4%から69.4%

履歴管理の上乗せ効果は文脈長を広げるほど縮み、32kから128kで35.7ポイントから2.7ポイントへ。強いモデルほどbashのみでコストが下がった(550B で SWE-Bench は53%減、Terminal-Benchは30%減)。

計画の追加は30Bで+11.6ポイント、550Bでは-2.0ポイントでコスト



約30%減。万能の最適設計を示すものではなく、Terminal-Benchは89課題で検出力に限りがあると著者ら。

出典 [arXiv\(査読前\)](#) ↗

短 信

〈AI規制〉AI各社の減速合意を巡り反トラスト訴訟

有料利用者4人が集団訴訟として提訴。9/12の減速提言が違法な合意と主張(訴状の主張) 出典 [CBS News](#) ↗

〈AI評価〉Anthropic、Accentureと埋め込み評価

各社が5年で10億ドル以上を投資。評価者が社内に入りモデルを検証 出典 [Anthropic](#) ↗

〈AI×生命科学〉Claude、生命科学の審査制アクセスを開始

審査通過チーム向けに生物分野の制限を緩和。高リスク用途は6か月更新 出典 [Anthropic](#) ↗

〈LLM効率化〉DeepSeek、KVキャッシュをV4-Flash比1/4に

V4.1-Flash(総552B)。1トークン890バイト、100万トークン対応(査読前) 出典 [arXiv\(DeepSeek-AI\)](#) ↗

〈マルチモーダル〉MiniMax-H3の物理世界推論、総合成功率42%

517事例。動画の意思決定56.0%に対し音声の曖昧性解消は27.4%(査読前) 出典 [arXiv](#) ↗

〈AI×歴史〉GPT-6 Astraが1918年の独軍暗号を解読と報告

個人ブログの報告。史料と整合と主張するが、独立した検証は確認できず 出典 [prinz\(Substack\)](#) ↗

〈ベンチマーク〉Brood War Bench、Codex Astraが18戦全勝

個人プロジェクト。著者は、どのモデルも初心者水準を超えなかったと評価 出典 [swardlow.dev](#) ↗

〈AIインフラ〉データセンターの電力費転嫁防止法案、下院可決

417対3。100MW超の負荷に系統増強費の負担基準を州が検討、上院待ち 出典 [Utility Dive](#) ↗