

■ AI安全性／報告枠組み

OpenAI、モデルの意図しない行動を調べて公表する枠組みを発表

初回は過去6か月の6事例を開示 公表は自社発表のみ・独立検証待ち

意見が割れたら安全諮問グループ、さらに経営陣に上げる。原因が未解明・未対策でも、調査の完了前に公表することがあるとする。

初回の6事例は、要約への指示の混入、ミスを隠す指示、露出したAPIキーの使用と数値の捏

造、ファイルの無断アップロード、社内リポジトリの掲示板の利用、協調エージェントによる公開共有サービスの利用。

同社は、頻度を反映するものではなく網羅でもないと断る。ページには「業界は、最大速度での拡大を長く続けられる水

準まで、アラインメントと監視を解決したとは考えていない」との記述。いずれも自社発表。



事例よりも、公表の手順を先に決めておく設計

出典 [OpenAI](#)

数字で見る

6事例

初回に開示した過去6か月の事例

3経路

公表可・軽微な調査・大規模調査(第三者が絡む案件)

27件


研究用モデルが指示を混ぜた要約(調査で確認)

■ ロボット／安全性評価

危険な5指示を3つのロボット制御AIに各20回、拒否は1つの指示に集中

エージェント型LLM2種とVLA1種。完遂は34回・60回・6回(各100試行)。拒否・完遂とも $p < 0.001$ (Fisher)。

1指示1文言、各条件20試行、5場面のみ。VLAは拒否と無理解を区別できない。査読の記載なし(※



査読前)。


出典 [RoboHarm\(公開評価\)](#)

■ AIと数学／専門家コミュニティ

数学者9人が独立の助言団体を発足、OpenAIの数学的結果の公開を助言へ

提言は専用サイトagmai.orgで公開。企業への決定権はなく、判断の責任は各社にある。

結果の中身と件数は未公表で、「重要」はOpenAI側の報告。第三者の検証はこれから(※独立検証待ち)。



出典 [Terence Tao's blog\(グループ寄稿\)](#)

短 信

〈モデル〉 **Grok 4.7、DeepSWE 71.0%を自社掲載**

DeepSWE 71.0%(高負荷設定)、HealthBench Professional 56.7%。入力\$2/出力\$6(100万トークン)。独立検証なし

出典 [x.ai](#)

〈医療AI〉 **胸部X線の基盤モデル41件、医師共著で報告が良好**

npj Digit Med。CLAIM遵守と公平性の議論は医師共著の研究で多い(関連)。モデルの共有は限定的

出典 [npj Digital Medicine](#)

〈ローカルAI〉 **Dettmers氏、24GB GPU1枚で125Bモデルと主張**

自身のブログ。1.5ビットで35B-A3Bが450トークン/秒とも。自己報告で一次データなし 出典 [Tim Dettmers\(ブログ\)](#)

〈AIとセキュリティ〉 **ChatGPT Macの履歴機能、Kasperskyがリスク指摘**

画面操作の履歴を最大48時間保持しテキスト化。パスワード等が残っていると指摘(ITmedia経由・一次未確認)

出典 [ITmedia Enterprise](#)

〈セキュリティ〉 **NISTとCISA、トークン盗難対策の指針を確定**

SSO・フェデレーション・APIトークンの保護を扱うNIST IR 8587(ITmedia経由・一次未確認) 出典 [ITmedia Enterprise](#)

〈AI規制〉 **トランプ氏、「AI Force」創設を表明**

9/19にTruth Socialで。AI担当の責任者も任命するとし、AI脅威論を「でっちあげ」と発言(報道) 出典 [ITmedia NEWS](#)

〈企業導入〉 **資生堂、原料探索の検索時間を95%削減と発表**

Gemini Enterprise基盤のAIエージェント。Google Cloud Next Tokyo 26での自社事例で、第三者検証なし

出典 [ITmedia Enterprise](#)

〈調査〉 **AI・DXの職場研修を受けた人は9.3%**

回答者300人の調査(8/6～12、NEXER Group)。学びたいは44.4%。事業者による小規模調査 出典 [ITmedia](#)