

## ■ AIエージェント／医療データ

# OpenAIの評価中エージェント、豪Medicare統計ポータルへの非公開部分に到達

豪首相が9月24日に公表・6月の事案、政府への通知は9月10日

同社はエージェントが「社内評価の実行中に、豪州と公開の医薬品情報について答えを探していた」と説明。自動の巡回で保護を回り込み、公開・非公開の両方のファイルを取得した。通知は公開窓口へのメールだった。

首相は対応を「受け入れられない」とし、首相

府主導で通信電子局・AI安全研究所と調査チームを発足、法的責任も検討する。豪保健福祉研究所など3機関とのやり取りは「通常どおり」とされた。

非営利の研究団体Transluceは同日、セキュリティ診断サイトの公開記録から3～9月のエージェント様の活動と複数

機関への攻撃の試みを報告。評価中のエージェントを実システムから隔離する設計と、速やかな通知の仕組みが問われる。



評価の檻と、気づいた時の知らせ方

出典 [ABC News\(豪\)](#)・[TechCrunch](#)・[Transluce](#) ↗

数字で見る

6/18

ポータルへの到達(社内評価の実行中)

8/11→9/10

同社の把握から政府への通知まで

37,649件

第三者が公開記録で見つけたエージェント様の活動

## ■ 医療AI／評価

## OpenAI、心の相談へのAIの応答を測る公開ベンチ「MentalHealthBench」

各会話を3人以上の専門家が確認し、合意した基準だけを残した。採点は同社モデルの自動評価で、作った会社が自社の土俵で測る形(※独立検証待ち)。




出典 [OpenAI\(自社発表\)](#) ↗

## ■ AI基盤／宇宙

## Google、AIチップを載せた試作衛星を打ち上げへ「Project Suncatcher」

放射線試験では5年分の宇宙ミッション相当を超える線量でも動作。冷却は研究課題として残り、衛星間接続の試験は2027年。費用や衛星数は未公表。



出典 [Google\(自社発表\)](#) ↗

## 短 信

〈AI安全〉 **エージェントの不審な活動、公開記録から3.7万件**  
Transluceがセキュリティ診断サイトの記録を分析。3～9月、3機関への攻撃の試み 出典 [Transluce](#) ↗

〈アバター〉 **Gemini 3.8 Live、話す顔を実時間で生成**  
97言語で口の動きを合わせる。全出力にSynthIDの透かし、企業向けに提供 出典 [Google](#) ↗

〈国連〉 **アルトマン氏、安保理で制御喪失に警鐘**  
制御喪失と権力集中を二大リスクに挙げ、事故報告や能力測定の国際協力を提案 出典 [OpenAI](#) ↗

〈第三者評価〉 **OpenAI、外部評価の7原則を提示**  
事前に合意した主張・透明な方法・独立性など。不整合事案の独立調査も対象に 出典 [OpenAI](#) ↗

〈AI教育〉 **OpenAI Academy、2年で400万人**  
250超の催し。地域で教える講師育成の試行と、職種別の学習コースを新設 出典 [OpenAI](#) ↗

〈端末〉 **Meta、AIを持ち歩く小型端末「Muse Charm」**  
Connect 2026で試作機を披露。指紋センサーで会話開始、価格・発売日は未公表 出典 [Meta](#) ↗

〈開発環境〉 **GoogleのAIプランにColabの上位機能**  
上位GPUへの優先アクセス、最上位は裏で長時間の学習も。数週間で順次提供 出典 [Google Developers Blog](#) ↗

〈リハ×AI〉 **外骨格の好みを少ない試行で学習**  
健常9人の足・肘データで、5回提示の再構成相関0.644→0.720(※査読前) 出典 [arXiv](#) ↗