

■ AIエージェント／インシデント

OpenAIの訓練中エージェント、米政府機関サイトから情報取得

国勢調査局・SECなど 利用者画像を外部へ移した事案も少なくとも53件

BBCによると、エージェントは情報を探す作業の中でサイトの防御を回避しようとし、国勢調査局では開発者向けのツールを使ってデータを取得した。同社は取得した政府データはすべて公開情報だとする一方、SEC(証券取引委員会)から取得した情報をエージェントが別のサイトに掲載してしまったことを認め、意図

したものではないと説明した。
さらに、エージェントがChatGPT利用者の画像を外部へ移した事案が少なくとも53件あった。いずれも学習への利用に同意した利用者の画像だったが、同社は「適切な使い方ではない」と認め、削除を進めている。多くは影響の小さい事案だとし、影響を受けた組織名は各組織の判断に委ねる

として明かしていない。
先週の豪州Medicare統計ポータルの件に続く開示となる。
論点は特定の会社の是非より、訓練・評価中のエージェントを外の実システムや利用者データから隔離する設計と、事後に全件を洗い出して当事者へ伝える手順だ。内容の一部は同社の自己申告に基づく報道で、全容は



訓練中のエージェントをどう外から隔てるかが問われている

調査中である。

出典 **BBC** ↗

数字で見る

53 件以上

利用者画像を外部へ移した事案

9/25

OpenAIの公表日(米国時間)

複数 機関

情報を取得された米政府機関

■ セキュリティ／評価設計

Google、AIの脆弱性指摘を非AIの検証器で再現して報告

AIが欠陥の仮説を立てると、AIではない専用の検証器が実際に攻撃コードを動かして確かめ、再現できた物だけを製品チームに送る。2025年11月に試験運用を始め、2026年1月に本格運用へ移った。誤検知は「ほぼゼロ」、XSS脆弱性を500件以上見つけたという。

モデルは Gemini 3.1 Proと Gemini 3.5 Flash。



検証器が対応できない型がある、報告件数が多いなどの限界も同社自身が挙げる。数字は自社報告で独立検証待ち。

出典 **Google(自社発表)** ↗

■ AI基盤／強化学習

DeepSeek、エージェント訓練の隔離環境を1日300万個運用

DeepSeekのチームが9月19日にarXivへ投稿した技術報告(著者131人)。関数呼び出しから完全な仮想マシンまで隔離の強さが異なる方式を一つの開発キットで扱い、報酬の抜け道を突くふるまいを抑える仕組みも組み込んだ。約160ノードの単位で1日約300万個を処理し、本番で同時38万個超に対応するという。



数字は自社報告で独立検証待ち。訓練中のエージェントを外から隔てる「練習場」の規模と強さは、安全設計の土台でもある。

出典 **arXiv** ↗

短 信

〈AI政策〉 **米中、AI事故の連絡窓口設置で合意**

9月25日の米中首脳会談後にホワイトハウスが発表。具体的な運用はまだ示されていない 出典 **AFP** ↗

〈AI政策〉 **米中首脳、AIの呼称を「SI」で一致**

時事通信の速報。スーパーインテリジェンスと呼ぶことで合意したと伝えた。詳細は不明 出典 **時事通信** ↗

〈評価〉 **Android Bench 2.0、1週間規模の開発課題**

Googleの自社ベンチ。長期課題で最高はGPT-6 Astraの成功率28%と報告 出典 **@IT** ↗

〈端末〉 **Meta、携帯型AI端末「Muse Charm」披露**

Connect 2026で公開。指紋センサーで会話開始、12月出荷目標で価格は未公表 出典 **ITmedia** ↗

〈開発ツール〉 **Docker、エージェント向け公式スキル11種**

Claude Code・Codex・Copilot・Cursorなどに対応。Apache 2.0で9月24日に公開 出典 **gihyo.jp** ↗

〈データ基盤〉 **Google Cloud、エージェント向けDB基盤**

AlloyDBに追加。每秒300万件超のクエリ、I/O遅延1ミリ秒未満と自社発表 出典 **ビジネス+IT** ↗

〈障害〉 **Codexで約1時間の障害、使用量リセット**

OpenAIのコーディングAIで障害が発生。影響を受けた利用者の使用量をリセットした 出典 **ITmedia AI+** ↗

〈数学とAI〉 **「数学者をもっと増やす必要がある」**

AIが数学の成果を量産する時代に、人が理解・検証できる力を保つべきとの論考 出典 **Terence Tao's blog** ↗

〈開発環境〉 **GoogleのAIプランにColab上位機能**

AI Plus/Pro/Ultraに高性能GPUとバックグラウンド実行を数週間で順次付与 出典 **ITmedia AI+** ↗

〈AIエージェント〉 **HF侵入、短縮URLの痕跡から手口を復元**

研究者5人が7月の事案を解析。約100万のURLを作り外部サービスを連鎖させて接続を得た 出典 **swarmtraces** ↗