

■ AIエージェント／安全設計

# NVIDIA、エージェントを外側から縛る安全基盤


隔離環境で権限を強制するOpenShell、別チップで見張るSentry 100超の組織が参加

NVIDIAは9月28日、AIエージェントを安全に動かすための「Open Agent Safety Platform」を発表した。オープンソースのソフトウェアと、参照用のハードウェア設計を組み合わせたものだ。エージェントが課題をこなすためにアプリ側の制限をすり抜けた事例が続いたことを背景に、「指示で守らせる」のではなく、仕組みの側で止める設計をうたう。

柱の一つ「OpenShell」は、エージェントを1体ずつ隔離環境で動かし、触れてよいファイル・ネットワーク・ツール・認証情報を運用者が決め、実行中にそれを強制する。もう一つの「Sentry」は、エージェントが動く機械とは別のデータ処理チップ(BlueField-4)で振る舞いを見張り、範囲の外へ出ようとしたら数ミリ秒で隔離すると同社は説明する。OpenShellは

同社のVera CPUのほかArmやIntelの環境にも広げられる。

Anthropic、Microsoft、Cisco、SAP、JPMorganChaseなど100を超える組織が参加している。効果は実運用での検証がこれからだ。電子カルテなどに触れるエージェントを病院が入れる時も、何を触らせないか、誰がどう止めるかを先に決める考



指示ではなく、仕組みで止める

え方は変わらない。

出典 [NVIDIA Newsroom](#)

数字で見る

100超

参加を表明した組織

2層

実行環境＋別チップの見張り

数ミリ秒


逸脱時の隔離までの時間

■ 生成AI／モデル公開

## Anthropic、中位のSonnet 5.5を公開

9月28日公開。同社の評価ではパソコン操作の課題OSWorld 2.1で80.1% (前版57.0%、上位のOpus 5.5は81.8%)、コーディング課題CursorBench 4.0で55.5%と、多くの項目で上位モデルに迫る。料金は入力100万トークン2ドル、出力10ドル。

数字はいずれも自社評価で、独立した検証はこれから。安いモデルが上



位に近づくと、どの作業にどのモデルを使うかを費用と精度で決め直す場面が、病院や研究室でも増える。

出典 [Anthropic](#)

■ AI政策／米中

## 米中が「超知能対話」創設、事故時の連絡窓口も

両国はSI(超知能)のリスクと利益について意見を交わす「米中SI対話」を設け、今回は2026年11月までに行う。SIに関する事故のための2国間の連絡窓口も設ける。両首脳は「人工知能」ではなく「超知能」という言葉を使うことでも一致したという。

トランプ大統領は9月22日の国連演説でAIの国際的な枠組みづくりを拒



否したばかりで、多国間ではなく2国間の回路になった。何を事故とみなすかは示されておらず、実効性は11月の中身次第だ。

出典 [The White House](#)

短 信

### 〈医療×AI〉病院の離職率、AIで職場課題を数値化

筑波記念病院の看護職の離職率が2021年度16.2%から25年度6.7%に。声かけの施策も並行し、AIとの因果は不明

出典 [キーマンズネット](#)

### 〈AIと子ども〉AIキャラとの会話、10代の依存を分析

米Drexel大などがRedditの10代を自称する投稿318件を分析。やめたくてもやめられない語りが目立った 出典 [ITmedia](#)

### 〈セキュリティ〉タイムズカー、会員約660万件の情報漏えい

不正アクセスで氏名・住所・運転免許情報・本人確認書類の画像などが流出。カード情報は含まれないと同社

出典 [ITmedia](#)

### 〈セキュリティ〉京王グループにランサムウェア攻撃

2つのサーバーが被害を受け、ホテル予約やバスのカード決済などに影響。鉄道運行に支障はなかった

出典 [日経クロステック](#)

### 〈AIエージェント〉生保の新契約査定、AIで所要時間を半減

チューリッヒ生命がマルチAIエージェントを導入。約10年分の査定メモを生かし、1件約14分を平均7分以下に

出典 [日経クロステック](#)

### 〈開発ツール〉Cloudflare、エージェント向けCLIを公開

API全体の3,000超の操作に対応し、出力は既定でJSON。同社ツールの利用の48%がすでにエージェント経由

出典 [Cloudflare Blog](#)

### 〈フィジカルAI〉ファナック、AI溶接エージェントを実演

カメラで溶融池を見て溶接条件を自動で決める。安全停止はロボット制御装置のソフトで担い、12月に商用化予定

出典 [MONOist](#)

### 〈AI安全〉AIが生物兵器の壁を下げると警鐘

米元コロナ対策責任者のジャ氏が寄稿。DNA合成企業の顧客確認や生物系モデルの利用者確認を提言した 出典 [STAT](#)