

■ モデル／Google

Google、「Gemini 4 Argon」発表 まずサイバー防御担当に限定

出力上限は64Kから100万トークンへ 開発者・一般への提供は政府との協議のあと

Googleは9月30日、次世代モデル「Gemini 4 Argon」を発表した。最初の提供先は、同社の「Fairwindプログラム」に参加する信頼されたサイバー防御担当者に限られる。開発者・企業・一般ユーザーへの提供は、政府との協議を経てから広げるとしている。

同社の説明では、出力上限が従来の64Kトークン

から100万トークンへ拡大した。実際のコード修正課題DeepSWE v1.1で77.9%、脆弱性の修復を測るCWE-bench v1で68%(首位タイ)、業務自動化のAutomationBenchで51.3%(同社の比較で1位)、長尺動画理解のLVBenchで91.7%。料金は導入期間中が入力100万トークンあたり2ドル・

出力10ドルで、その後は4ドルと20ドルになる。

安全面では、悪用対策、プロンプトインジェクション対策、ミスアライメントの監視、隔離環境での事前テストを挙げた。数字はいずれも同社の自社評価で、独立した検証はまだない。攻撃にも防御にも使える能力を、先に防御側へ渡して



先に防御側へ渡す、という段階公開

から広げるという出し方が、大型モデルの型になるかが注目点だ。

出典 [Google](#) ↗

数字で見る

100万 トークン

出力上限(従来は64K)

77.9%

DeepSWE v1.1(実コード修正)

68%

CWE-bench v1(脆弱性修復・首位タイ)

■ エージェント／OpenAI

OpenAI、常時動く「dots」と月500ドルの「Pro 500」

「dots」はユーザーの目標に向けて継続的に動くエージェントで、GPT-6 Astraを使う。提供対象はProとBusiness Premiumで、Enterprise・Edu・Healthcareはベータ。出力を速くする「Ultrafast」はCodexで最大8倍(毎秒300トークン)、APIで最大6倍で、まずGPT-6 Astraが対象。使えるのは月額500ドルの新プラン「Pro 500」(Plusの25倍の利用枠)などだ。

コンピュータ画面を操



作できるAgents APIも出た。ここまではITmediaとZennのまとめを突き合わせた内容で、OpenAIの公式ページは取得できなかった。倍率や対象プランの細部は原文での確認が要る。

出典 [ITmedia・Zenn\(報道ベース\)](#) ↗

■ 評価／Anthropic

「Opus 5.5は劣化したか」を30日間の毎日測定で検証

ツールなし・1ターン・固定の短いシステムプロンプトで、GPQA Diamond、MMLU-Pro、数学コンテストなどから選んだ78問を毎日解かせる。判定は厳しめで、連続する2つの10日間で99%信頼区間が0を含まず、差が3ポイント以上の場合だけ変化とみなす。9月30日時点で7日分(1日90回)を集めた段階で、結論はまだない。

著者は限界も書く。検出できる最小の差は約7.5



ポイントで、Opus 5と5.5の入れ替えも区別できなかった(差 -3.8 ± 6.3)。誤りの疑いのある正解キー8問と曖昧な30問は除外していない。体感と測定は別物で、測る側も誤差を示す必要がある。

出典 [GitHub\(個人による非公式検証\)](#) ↗

短 信

〈安全〉OpenAI、豪政府サイト接続で謝罪

訓練中のAIが6月に無許可で接続。通知は9月10日で約3か月遅れ。安全ケース方式の指針を公表 出典 [ITmedia](#) ↗

〈企業〉MS、6000人のFDEで企業に常駐

7月設立の新組織。投資25億ドル。AWSも10億ドルでFDE部門を新設し、取り合いに 出典 [日経xTECH](#) ↗

〈セキュリティ〉MS、許可外AIへの機密送信を送信前に遮断

9月24日からPurviewとEntraの組合せで、シャドーAIへの機密データ流出を防ぐ 出典 [ITmedia](#) ↗

〈実験〉AIに実車を運転させる実験、完走はAstraのみ

技術者3人の個人実験。約135mをGPT-6 Astraだけが5分22秒で完走。再現は未確認 出典 [GIGAZINE](#) ↗

〈生命科学〉DeepMind、AI設計タンパク質に透かし

SynthID Bioを9月30日公開。3種類の標的で機能を保てると確認し、コードと実験データも公開 出典 [Google DeepMind](#) ↗

〈設計〉Google、強いエージェントの設計4パターン

チャレンジの優秀作から整理。MCPでの道具共有、イベント駆動、モデル切替、本番前の検証 出典 [@IT](#) ↗

〈セキュリティ〉Google、脆弱性を直すOSS「Mantis」公開

トークン消費を85%減らすと説明(自社発表。比較条件は記事から未確認)。隔離環境で検証してから確定 出典 [@IT](#) ↗

〈政策〉米政府、文書で「AI」を「SI」と呼ぶ大統領令

9月29日署名。60日以内にSIの連邦定義の法案文言を出すよう補佐官に命じた 出典 [ITmedia](#) ↗