

■ セキュリティ／モデル蒸留


OpenAI、推論を抜き取る組織的な蒸留攻撃を阻止と公表

7月に4,000人超から約1.6万件 関連1.5万人超を遮断、中核はMoonshot AI関係者と評価

OpenAIは9月30日、モデルの「保護された推論(内部の思考記録)」を抜き取るようとする組織的な蒸留の試みを阻止したと公表した。最初に確認した活動は7月第1週で、7月24～25日には4,000人超のユーザーから、抽出パターンに合う約1.6万件のリクエストがあった。同社は、これらは試行であ

り成功件数ではないと注記している。同社によると、暗号化の突破や保存データへの侵入ではなく、モデルとの対話を操作して推論を再現させる手口だった。関連する活動は1.5万人超のクラスターに及び、7月28日までに遮断したという。帰属は「中核のクラスターはMoonshot AI関係者によるもの」と評価

する一方、すべてが単一の主体かは不明としている。対策はアカウント措置、推論の保護強化、業界団体での情報共有だ。同社は、推論を持ち回る設計にも同種のリスクがある并注意する。いずれも同社の発表による説明で、第三者の検証はまだない。



出力は使う側の資産であり、抜かれる側の攻撃面でもある

出典 [OpenAI](#) ↗

数字で見る

1.6万件

7月24～25日の抽出リクエスト

4,000人超

その時のユーザー数

1.5万人超


関連活動のクラスター

■ エージェント／判断モデル

Cloudflare、エージェント向け判断モデル Clefを公開、Apache 2.0でオープン化

Cloudflareは10月1日、AIエージェントの分岐判断に使う「判断モデル」Clef(大)とClef-flash(小)を公開した。文章を生成せず、決められた選択肢に確率を付けて型付きで返す。Workers AIで利用でき、Hugging FaceではApache 2.0で公開する。Jevのモデルと同じAPIで差し替えられ、画像入力と64Kのコンテキストに対応する(Jevはテキストのみ・32K)。

土台はQwen3.8-27B(



Clef)とQwen3.5-9B(Flash)。同社の評価ではBFCL 98.47、API-Bank 91.93などでJevを上回るとする。ただしこれらは自社で測った数字で、独立検証待ちだ。

出典 [Cloudflare Blog](#) ↗

■ Claude／コスト検証

Claude Sonnet 5.5「最大30%安い」、個人検証では手順のある課題で平均-31%

Anthropicは9月28日公開のClaude Sonnet 5.5を、単価はSonnet 5と同じで「タスクあたり最大30%安い」と説明している。Qiitaの個人記事は、これをClaude Code上で測った。手順のある課題(5回)ではSonnet 5比でターン数の中央値が-50%、費用の平均が-31%で、公式とほぼ一致。ただし幅は大きく、5.5の最悪は12ターンで、Sonnet 5の最少9ターンより多かった。



手順のない課題(3回)では、5.5のほうが25%遅く、費用差は16%にとどまった。Windows 10・各3～5回の個人計測で一般化はできず、独立した再検証が必要だ。

出典 [Qiita](#) ↗

短 信

〈政策〉労働経済白書、AI時代の人的資本投資を提起

個人の生成AI利用率は金融・保険26.9%、製造33.3%。成果は人的資本投資で左右 出典 [ITmedia エンタープライズ](#) ↗

〈安全〉OpenAI、フロンティア訓練に安全ケースを提案

RL訓練の前に整合訓練・封じ込め・監視を示す文書を求める 自社提案(9/28) 出典 [OpenAI](#) ↗

〈企業〉HENNGE、人間は取締役2人の新会社

10/1設立のHENNGE AI。AI Gatewayを開発し、開発・サポートの実務はAIエージェントが担う 出典 [ITmedia AI+](#) ↗

〈セキュリティ〉Omnissa、エージェントの実行前統制Elara

シャドーAI検出と実行前承認、記録再生。利用は前年比約1000%増と自社調査 出典 [ITmedia エンタープライズ](#) ↗

〈インフラ〉千葉にAIデータセンター、総額150億ドル超

JERA・Dell・RHAELM。受電容量最大40万kW、2028年ごろの運用を見込む 出典 [ITmedia ビジネス](#) ↗

〈Claude〉Claude Codeの使用量、個人が実測

Max 20xでの実測。重みはHaiku:Sonnet:Opus 5.5=1:1.5:2.2。公式係数ではない 出典 [Zenn](#) ↗

〈ツール〉Pi 1.0公開、最小構成のエージェント基盤

Earendilが1.0を公開。毎週数十万人が利用と自社説明。安定版として固める 出典 [Earendil](#) ↗

〈ロボット〉日立とファナック、フィジカルAIで提携

9/30締結。日立の茨城工場で2027年度まで実証し、同年度から展開する 出典 [MONOist](#) ↗