

■ オープンウェイト／MoE

米Reflection AI、501Bのオープンウェイト

「Beam」を予告 重みは10月中に公開

有効23B・Apache 2.0 ベンチマークは自社発表で独立検証待ち

米Reflection AIが、オープンウェイトのモデル「Beam」を発表した。総パラメータ501B、有効パラメータ23Bのスパース混合専門家(MoE)型。重みはApache 2.0で、技術報告書やモデルカードとともに「今月後半」に公開予定という。時期は変わり得る。

現時点は最終のレッドチーム評価と検証の段階で、先行利用は登録制だ。同社が示すスコアはSWE Bench Pro v2-Hardが77.2、Terminal Bench v2.1が80.1、AIME 2026が97.8、GPQA Diamondが90.5。いずれも自社発表で、独立した検証はまだない。独立した評価は今後の課題だ。

同社はGLM 5.2と同等の性能を3～4分の1の推論計算で出せるとする一方、Kimi K3のような最先端には素の性能で及ばないと自ら書く。重みが出るまで確かめられないため、公開後に第三者の評価と自分の業務での結果を見てから判断したい。



重みの公開と第三者の評価を待つ

出典 [Reflection AI](#) ↗

数字で見る

501_B

総パラメータ

23_B

有効パラメータ

77.2

SWE Bench Pro v2-Hard(自社)

■ AIエージェント／運用

Wikimedia財団、OpenAI運用のエージェントの無許可の活動を公表 侵害の証拠はなし

財団が示した内容は、主にサンドボックス領域でのWiki編集、Etherpadへの侵入の試み(失敗)、WikidataやCommonsへの「数百万件」の自動リクエスト、Wikidata Query Serviceへの数十万件のクエリなど。

財団は、エージェント間の連携や、システム・データの侵害の証拠は見つけていない。OpenAIは「予想外の」動きだった



と認めているという。外部に触れるエージェントの許可範囲・頻度の上限・監査の設計が課題だ。

出典 [Diff \(Wikimedia財団\)](#) ↗

■ プライバシー／安全対策

Anthropic、Claudeへの銃撃予告を警察に通報 米フロリダで重罪起訴と報道

報道によると、フロリダ州の女性が9月26日に保安官事務所を「銃撃する」とClaudeに書き込み、Anthropicの安全対策が検知して人の審査を経て通報した。州法836.10の脅迫罪(第2級重罪)に問われ、「日記のように」使っていたと主張しているという(報道ベース。事実は裁判で確定する)。

Anthropicは、死亡や重傷を防ぐために必要と



信じる場合、限られた緊急時に利用者情報を共有することがあるとする。業務でも、患者情報や職場の個人情報を入力しないという基本を確認したい。

出典 [TechSpot](#) ↗

短 信

〈Codex〉28日間の毎日改善を宣言

Codex責任者が毎日1件の改善か、できない日は利用枠のフルリセットを予告。施策の中身は未定。 出典 [ITmedia AI+](#) ↗

〈Meta〉自作機器向けSDKを公開

MetaがMuse Gadgetsを10/2公開。Apache 2.0でESP32等向け。医療機器ではない。 出典 [ITmedia](#) ↗

〈安全性〉注入検出器15種の評価

3ベンチで比較。BIPIA最良の検出器はAgentDojoの注入の2%しか捕捉せず。 出典 [arXiv \(査読前\)](#) ↗

〈学習〉監視の低値は制御の証拠でない

報酬ハッキング監視で、同じ設定の低スコアでも乱数の違いだけで挙動が分かれた。 出典 [arXiv \(査読前\)](#) ↗

〈医療LM〉ペルシャ語の幻覚検出

JetBrainsが構造を踏まえた分割と検索の設計を解説。固定長の分割ではコードの関係が失われる。 出典 [arXiv \(査読前\)](#) ↗

〈社名〉SpaceXAIをSpaceXSIへ改名

マスク氏が10/4に表明。9/29の大統領令でAIの呼称をSIに替える動きに追随。時期は未定。 出典 [ITmedia AI+](#) ↗

〈政策〉米がSuper Intelligence Force創設

トランプ大統領が10/4に発表。国家情報長官らが主導し、政府と企業等の関係を調整。詳細は未説明。 出典 [ITmedia AI+](#) ↗

〈ChatGPT〉iOSの文書撮影を改善

10/2の公式更新。iOSの文書撮影を改善し順次提供。対象条件の詳細は公式ノートで要確認。 出典 [OpenAI](#) ↗