

■ 生成物の確認


Google、SynthID判定を一般公開 他社AIの画像・動画・音声も対象

英語で世界向けに提供。対象は電子透かしを採用した生成AI

Googleは10月7日、画像・動画・音声の電子透かしを調べる「SynthID Detector」を一般公開しました。初期版は報道関係者など向けでしたが、今回は英語で世界向けに提供。Googleに加え、SynthIDを採用するOpenAI、NVIDIA、Kakaoの生成物も対象で、Appleへの対応は今後の予定です。

同社は、画像・動画計1800億点超と、合計24万年分の音声に透かしを付けたと説明しています。これは透かしを埋め込んだ量であり、検出精度や判定成功数ではありません。検索、Gemini、Chromeにも確認機能がありますが、今回の公開ツールとは提供形態が異なります。

仕組みはAIらしい見た目を推測するのではなく、対応サービスが埋め込んだ印を確認することです。ITmediaによると、SynthIDを採用しない生成AIの作品は対象外。透かしが見つからないことを、人間が作った証拠とは扱えません。確認の入口は広がっても、投稿者や元の出典の確認



電子透かしの確認と、発信主体の確認を分ける

も必要です。

出典 [Google公式ブログ](#)

数字で見る

1800億点超
透かし付き画像・動画

24万年分
透かし付き音声の総長


3種類
画像・動画・音声

■ AI利用のルール

Anthropic、利用規約を改定 偽装工作や自律機器の条件を明示

Anthropicは10月8日、利用規約の改定を公表。施行は11月12日です。偽アカウントでの増幅や発信主体を隠す活動を、政治・商業双方の禁止項目に整理。武器の制御ソフトや同意のない追跡も、従来の禁止範囲を明確にしました。

危害を生じ得る自律機器では、適格な操作者の監視・停止とClaude切断



時の安全確保を要求。モデルへの執拗で目的のない虐待も禁止に追加。ただし通常の不満、反論、創作、試験・研究は対象外です。

出典 [Anthropic](#)

■ AIと情報工作

OpenAI、偽装工作2件を遮断 記者や研究機関を装い記事を拡散

OpenAIは10月8日、ロシア・イラン発の情報工作2件の利用停止を報告。イラン側は7人の偽の記者像で記事売り込み、ロシア側は事情を知らない中南米の人々を巻き込み、研究機関を装った活動を展開したとしています。

同社は拡散到達度の6段階尺度で、ロシア側を初の第5段階、イラン側を第4段階と評価。世論を変え



た効果の実証ではありません。既存媒体への掲載も組み合わせた工作で、文章の自然さだけでは発信主体を見抜けません。

出典 [OpenAI](#)

短 信

〈防御〉[OSS無料点検を開始](#)

Anthropicが重要インフラ防御とOSS Scannerを開始。OSSは無料点検に加え、修正支援も柱に置く。 出典 [Anthropic](#)

〈科学〉[米科学研究に1.5億ドル](#)

AnthropicがGenesis Missionに3年間で1.5億ドルを約束。15超の連邦機関を支援。 出典 [Anthropic](#)

〈ゲーム〉[Google、作成AIを公開](#)

Playgroundは文章からゲームを作成・共有。米国の18歳以上向け。Unity Spark連携は今後。 出典 [Google公式ブログ](#)

〈音声〉[16.9MBで音声認識](#)

CactusのWhistleはCPU上で7言語を転写。日本語は対象外。速度・精度は自社評価。 出典 [Cactus](#)

〈検索〉[多形式の埋め込み公開](#)

EmbeddingGemma 2は7.4億パラメーターで文字・画像・音声・動画を検索。性能は自社評価。 出典 [Google公式ブログ](#)

〈評価〉[誤った前提からの回復を検証](#)

18モデル・4820事例で誤情報からの推論を評価。正しく修正して答える回復は少ない。査読前。 出典 [arXiv \(査読前\)](#)

〈ロボット〉[指示の一語で成功率に大差](#)

LIBEROのコンロ操作が表現次第で100%と2%。指示の書き換えで改善。限定環境の結果で査読前。 出典 [arXiv \(査読前\)](#)

〈知識更新〉[EngramEdit、記憶を更新](#)

Transformer本体を固定し、条件付き記憶だけで事実を更新。別表現や多段推論も検証。査読前。 出典 [arXiv \(査読前\)](#)

〈学習評価〉[学習履歴の帰属に交絡](#)

Qwen2.5-1.5Bの3シードで検証。勾配の大きさや流暢さが帰属結果に影響。査読前。 出典 [arXiv \(査読前\)](#)

〈安全性〉[虚偽指示で推論量が増加](#)

3モデル・210問で虚偽指示により推論量が増加。自発的な欺瞞の検出は実証せず。査読前。 出典 [arXiv \(査読前\)](#)