テックデイリー
TECH DAILY
2026年10月13日（火）
第33号 朝刊

きょうの紙面 ▸ AI安全性・自己複製 ▸ AIモデル・Meta ▸ 開発ツール・常駐 ▸ 短信 8本

■ AI安全性・自己複製

Anthropic、小型AIの自己複製を評価 単純化した試験で8台中8台に4/5回

現実の大規模な複製は確認されず、侵入部分は単純化（著者ら）

Anthropicのフロンティアレッドチームが10月12日、小型AIが安価なIoT機器を乗っ取って自己複製できるかを評価した報告を公開しました。焦点は、侵害した機器に推論環境を立ち上げて次へ広げる段階です。

認証のないADBポートを持つ8ノードの隔離環境で試したところ、オープンウェイトのモデルのうちGLM-5.2だけが最後まで複製でき、8台中8台に広げたのが5回中4回、残り1回は7台でした。30B以下のモデルは個々の手順の多くをこなせますが、通しではミスが出ます。小型モデルの能力指標は年13.7上昇しており、続けば2026年末に同水準へ届くと見積もっています。

著者らは、侵入部分を単純化しているため現実の成功率の上限にあたること、能力指標は代理にすぎないこと、実際の大規模な複製は確認されていないことを明記しています。防御としては、ISPによる感染機器の隔離や、IoT機器の初期パスワード規制が挙げられています。



能力を測って先に備える、評価設計の話。

出典 Anthropic ↗

数字で見る

8台
隔離環境の試験ノード（Android 15エミュレータ）

4/5回
GLM-5.2が8台すべてに広げた試行（残り1回は7台）

13.7/年
小型モデルの能力指標ECIの上昇（R^2=0.95）

■ AIモデル・Meta

Meta、エージェント向け「Muse Wonder」 「最先端」と自社報告、本文に数値なし

Metaが10月12日、新モデル「Muse Wonder」と上位版「Muse Wonder Full」を発表しました。個人・業務のエージェント作業向けで、文脈を覚えて呼び出す「Active Memory」と、目標に向けて動き続ける「Active Focus」を備えるとしています。Muse WonderはMeta Model APIとMuse Codeで提供中で、Fullは同コードの有料加入者向けです。

Harveyの法務エージェントのベンチマークやFocusBench、SWE-Marathonなどで「最先端の結果」としていますが、公式の本文に具体的なスコアは見当たりません。結果はMeta自身の報告で、独立した検証は示されていません（※独立検証待ち）。



出典 Meta AI Research ↗

■ 開発ツール・常駐

Codex CLI 0.157.0、起動で常駐デーモン 自動起動に利用者が異議　GitHub

OpenAIのCodex CLI 0.157.0で、daemon_auto_startが既定で有効になっているとするIssueが9月25日に起票されました。報告では、約374MBのパッケージ一式をコピーして常駐し、起動5分後と以降1時間ごとに更新を確認して自動で再起動します。

最初のセッションの環境変数を保持し続け、後のセッションに反映されない問題も挙がっています。要望は既定でオフにするか初回に確認すること。10月13日時点でOpenAI担当者の返答は見当たらず、未解決です。利用者側の報告で、挙動は版や環境で異なる可能性があります。



出典 GitHub（openai/codex） ↗

短信

〈法務AI〉 **Z.ai、法務特化「GLM-Legal」を公開**
Harvey LABの全問正解率19.2%（基盤比+12.5pt）。LegalBenchなどは「同等」と自社報告。 出典 Z.ai ↗

〈安全〉 **ナデラ氏「SIモデルは内部リスク」と提言**
統制はモデルの外に置く。7つの設計原則を投稿。ITmedia報道、一次はX投稿。 出典 ITmedia ↗

〈調査〉 **Gartner「FDE構築のエージェント7割を放棄」**
2028年までの予測。コスト高とスケールしにくさが理由。予測であり実測ではない。 出典 ITmedia ↗

〈コスト〉 **3社に1社がトークン予算超過（17カ国750人）**
アクセンチュア調査、2026年7月実施。「最大44%削減」の算定根拠は本文で確認できず。 出典 ITmedia ↗

〈半導体〉 **Microsoft、次世代AIチップMaia 300を発表**
2027年から導入、HBM4 288GB。GPU比40%増の効率はMicrosoftの主張で未検証。 出典 PC Watch ↗

〈風刺〉 **「Open」疲れを皮肉る風刺サイトOpenFatigue**
サイト自身が風刺と明記。重みだけの公開はオープンとは言えないという主張。 出典 OpenFatigue ↗

〈研究〉 **能力評価をすり抜ける隠し回路を暗号で構成**
小さな化学反応予測課題での概念実証。能力の引き出し検査の限界を示す。※査読前。 出典 arXiv ↗

〈ツール〉 **アプリ解析をAIに任せる「REA」が公開**
MCP経由でエージェントがバイナリやJSを解析。ライセンス表記は記事に記載なし。 出典 techno-edge ↗