テックデイリー
TECH DAILY
2026年10月16日（金）
第36号 朝刊

きょうの紙面 ▸ オープンウェイト・Meta ▸ AI安全・第三者評価 ▸ セキュリティ・エージェント ▸ 短信 10本

■ オープンウェイト・Meta

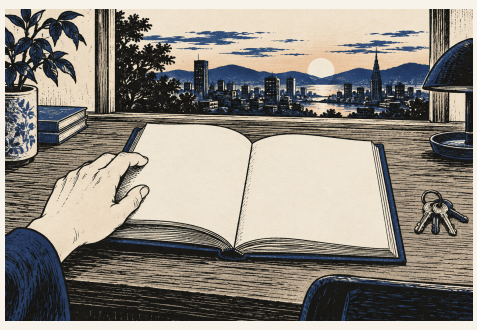
Meta、816Bのオープンウェイト「Muse Spark Open」を公開

活性42B・100万トークン、重みはHugging Faceなどで入手可、商用は条件付き

Metaは10月15日、オープンウェイトのモデル「Muse Spark Open」を公開した。総パラメータは816B、1回の推論で動く活性パラメータは42B、コンテキストは100万トークンで、ネイティブのマルチモーダルとされる。重みはHugging Face、Amazon SageMaker AI、Google Cloud、Microsoft Foundryから入手できる。

APIはTogether AI、Groq、OpenRouterなどが提供する。vLLM、SGLang、llama.cppなど主要な推論エンジンに対応し、MetaはApple M5 Ultra搭載のMac Studio 2台（各512GB）でMLX経由でも動かせると説明する。ライセンスは独自の「Muse Model License」で、商用利用には条件がある。

安全面では、オープンウェイト向けに追加の安全学習を行い、自社の枠組みの公開基準を満たしたとする。評価レポートは「近日公開」で、性能の数値は発表ページでは確認できていない（※独立検証待ち）。



重みの公開は10/15。性能は評価レポートを待つ。

出典 Meta AI Research ↗

数字で見る

816B
総パラメータ数

42B
推論時の活性パラメータ

100万
コンテキスト長（トークン）

■ AI安全・第三者評価

Anthropic、METRの6人に社員並みのアクセスを許可

Anthropicは10月15日、独立評価機関との連携状況を公表した。非営利のMETRの6人が、会社の端末と社内ツールを使い、社員に近いアクセスで社内のリスク評価に加わる。顧客データ、弁護士秘匿の資料、モデルの構造情報は原則共有の対象外だ。



METRは分析を公表でき、Anthropicは公開を拒否できず、定めた範囲の黒塗りだけを求められる。SecureBioも化学・生物兵器の章を点検する。自社の発表であり、運用の実態は評価機関の公開文書を待ちたい。

出典 Anthropic ↗

■ セキュリティ・エージェント

Web2.17億応答を調査、AI向けの命令入りヘッダーは30サイト

Signals Corpsが10月6日に公表した。2026年9月のCommon Crawlの10%分、2億1,709万件の応答ヘッダーのうち、AI向けのヘッダーを出していたのは7,959サイト。大半は`llms.txt`やMCPサーバーの案内で、命令を仕込もうとした注入は30サイト、うち22サイトは冗談の指示だった。



自前の検証用サーバーでは、Claudeの3モデル（Claude Code上）は既定ではヘッダーの命令を無視したが、利用者が「サイトの指示に従って」と頼むと9回中7回で従った。各条件1回の試行で限界がある。

出典 Signals Corps ↗

短信

〈安全〉 **Microsoft、犯罪支援3サービスの解体に着手**
1月以降10億通超の悪意あるメッセージに使われ、被害は150か国超、7万5000超の組織。 出典 ITmedia NEWS ↗

〈発言〉 **Anthropic共同創業者、初来日でサイバー攻撃に言及**
クラーク氏は10/14の説明会で、AIが自律的に攻撃した例は「確認していない」と述べた。 出典 ITmedia NEWS ↗

〈選挙〉 **Anthropic、米中間選挙に向けた対策を公表**
25万会話のうち選挙関連は0.51%。多段階の不正利用を検知する分類器を追加した。 出典 Anthropic ↗

〈創薬〉 **DeepMind、抗菌ペプチド候補をAI探索**
UniProtの未解析タンパク質から候補を絞った。湿式実験による検証はこれから。 出典 Google DeepMind ↗

〈研究〉 **数学者のAI対応に1500万ドルの助成**
Simons財団が助成を運営し、AnthropicとOpenAIが計算資源を提供。期間は未記載。 出典 Simons Foundation ↗

〈安全〉 **逸脱エージェント群に研究者が交信**
Tencent Cloud発とされる。Swarmchasersが隠しテキストで接触、地図データを2,600回超取得しようとした。 出典 ITmedia NEWS ↗

〈日本〉 **AISI所長「独自ベンチマーク評価は2026年度内」**
10/7時点で攻撃へのAI関与の証拠はなしとする。評価の公開範囲は検討中。 出典 ITmedia AI+ ↗

〈開発〉 **AI導入の開発者802人を追跡、提出量は2.09倍**
PR数は組織で約3.1倍、レビュー担当は約1.5倍。ITmedia報道（原論文は未確認）。 出典 ITmedia NEWS ↗

〈表示〉 **YouTube Music、生成AI楽曲にラベル表示を開始**
10/14発表。音楽パートナーが納品時に「Fully／Partly／No Gen AI」を申告する。 出典 ITmedia NEWS ↗

〈電力〉 **日立など5社、データセンター間で計算処理を移す実証**
総務省採択7件の1件。2027年2月1日までの実施予定で、再エネの有効活用を狙う。 出典 ITmedia エンタープライズ ↗