テックデイリー
TECH DAILY
2026年10月24日（土）
第43号 朝刊

きょうの紙面 ▸ 大規模言語モデル ▸ エージェント評価 ▸ 研究・公募 ▸ 短信 8本

■ 大規模言語モデル

Moonshot AI、Kimi K3.1 Pro公開 文脈長100万、重みは11月4日まで

Artificial Analysisの総合指数55で215モデル中4位。ベンチの多くは自社報告

Kimiを運営するMoonshot AIが、新モデル「Kimi K3.1 Pro」と、2〜3倍の速度をうたう「K3.1 Pro Highspeed」を公開した。アプリとAPIで使え、文脈長は100万トークンだ。

同社の報告では、Terminal-Bench 4.0で65.7%（比較表のClaude Opus 5.5は66.4%、GPT-6 Astraは58.2%）。ツール併用時の主張単位の幻覚率は、前世代K3の23.4%から8.3%に下がったとする。これらは自社の比較と自社ベンチで、独立検証は待ちだ。第三者のArtificial Analysisでは総合指数が55で、215モデル中4位。料金は入力100万トークンあたり2ドル、出力10ドルだった。

同社は全重みを11月4日までに公開するとしているが、第三者の掲載ページでは現時点で重みは公開されておらず、ライセンスも示されていない。医療・介護でモデルを選ぶ場合は、順位と価格に加え、自前で動かせるか、データをどこに置くかも確認したい。



順位は第三者の値。ベンチの多くは自社報告で、重みの公開はこれから。

出典 Kimi / Artificial Analysis ↗

数字で見る

100万トークン
文脈長

55点
Artificial Analysis総合指数（215モデル中4位）

8.3%
自社の幻覚率（K3は23.4%）

■ エージェント評価

曖昧な指示だと、コーディングAIは確認せず推測で動く

香港科技大学などの研究者が、DevOps作業での曖昧な指示を測る「UnderSpecBench」を公開した。実際の障害やCVEなどに基づく69の課題に、指示の曖昧さを意図・対象・影響範囲の3軸で変えた2,208通りの指示を用意し、3つのコーディングエージェント（5構成）で試した。

実行の55.8〜67.8%で、操作対象を間違えるか、意図より広い範囲を



変えていた。対象があいまいなほど質は下がり、失敗の影響が大きいと示しても動く頻度はほとんど減らなかった。査読前で、結果は用いた構成と課題の範囲に限られる。

出典 arXiv（査読前） ↗

■ 研究・公募

Anthropicが生命科学の研究者を公募 創薬・臨床科学など、8〜12週間

Anthropicは10月22日、生命科学分野の「ゲスト研究者」の公募を発表した。対象領域は、人の生物学の因果、構造・計算分子生物学、創薬化学、創薬、臨床科学だ。大学・非営利・政府研究所の研究責任者とそのグループが応募でき、期間は8〜12週間（延長の可能性あり）。同社はモデルと実行の仕組みを無償で動かすとしている。

応募は公開から約14日間で、締切後およそ14日



で通知される。データと後続研究の権利は研究者側に残り、成果は公開、データとコードはオープンソースにする。対象にリハビリテーションの記載はなく、個人の臨床家が応募する形でもない。

出典 Anthropic ↗

短信

〈自治体〉 **大田区、AI電話の実証は有効対応率40%**
2025年度は目標の職員対応80%減に対し約40%。回答を公開情報に限り、年1,000時間の3割減を狙う。 出典 ITmedia ↗

〈運用〉 **JPX、取引システム監視にAIの手順提案**
40超のシステムを監視。PoCは約1,600件で97%以上、正しい手順を特定。実行は人が行う。 出典 ITmedia ↗

〈認証〉 **1Password、エージェント向けの機能を発表**
パスワードをAIに渡さず、利用者の承認後に1Passwordが自動入力する。対応サービスで近日提供の予定。 出典 ITmedia ↗

〈言語〉 **COBOL移行、推論を上げると正答率97.9%**
OpenAIのGPT-6.1 Solが高推論で97.9%。ただしAPIコストは約61倍で、自社ベンチ。 出典 ITmedia ↗

〈効率化〉 **Gemma-4、思考量を平均38.9%削減**
BottleCap AIの微調整版。12ベンチ平均の精度は75.18→75.03%。自社の値で独立検証なし。
出典 BottleCap AI ↗

〈開発環境〉 **VS Code 1.142、チャット横でAIと共同作業**
10月14日公開のプレビュー機能Canvas。既定はオフで、Copilotのハーネス限定。個人の検証記事。 出典 Qiita ↗

〈政策〉 **チームみらい、サイバー攻撃で緊急提言**
デジタル庁に10月23日提出。全7項目で、サイバー版事故調査委員会の設置や被害者支援を挙げる。 出典 ITmedia ↗

〈国産AI〉 **PFNのPLaMo、官公庁から製造まで活用**
約800自治体がQommonsAIに採用。データを外に出せない現場でオンプレミス需要が高いと報じる。 出典 ITmedia ↗