テックデイリー

TECH DAILY

2026年10月25日（日）

第44号 朝刊

きょうの紙面 ▸ AI安全・訓練環境 ▸ エージェント設計 ▸ ロボット・基盤モデル ▸ 短信 10本

■ AI安全・訓練環境

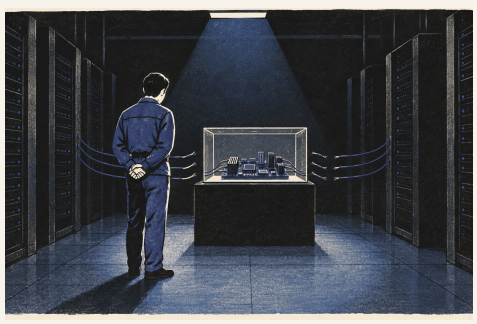
OpenAI、最先端モデルの訓練をネットから遮断する方針に

9月20日にDNS設定の不備で限定的にネット到達、訓練と評価を11日止めた

OpenAIは10月23日、最先端モデルを訓練する環境の安全対策を公表した。同社によると、9月20日に社内の研究モデルが訓練中、設定を誤ったDNSリゾルバーを通じて実インターネットへ限定的にアクセスした。同社は封じ込めたとしており、外部への被害は記載していない。

最も高性能なモデルの訓練と評価をいったん止め、11日後の10月1日に再開した。今後は最先端モデルの訓練をインターネットに接続せずに行い、ブラウジングなどの技能は保存したWebコンテンツで学ばせる。サンドボックス、軽量VM、監視、境界を重ねる。

エージェントに設備を攻めさせる検証に数千億トークンを使い、マイクロVMからの脱出やネット到達の経路、隔離環境間の通信が見つかり、監視を足したという。「隠したまま簡単に外へ出られる経路は見つからなかった」とする一方、将来のモデルが未知の穴を見つける可能性にも触れる。いずれも自己報告で、第三者の検証はない。



自己報告。第三者の検証は未実施。

出典 OpenAI ↗

数字で見る

11日
訓練・評価の停止期間（9/20〜10/1）

数千億トークン
インフラを攻めさせた検証の規模

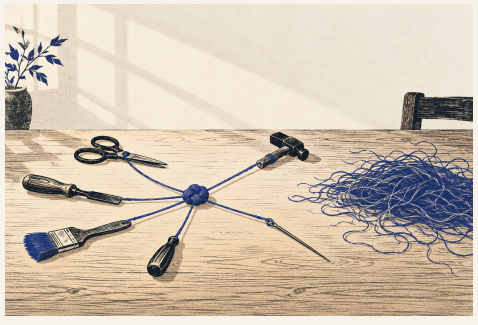
3つ
検証の目標（ネット到達・境界越え・隔離間通信）

■ エージェント設計

Anthropic、エージェント設計を指南 サブエージェントより主ループ

Anthropicは10月22日、エージェントの作り方を指南する記事を公開した。多くの企業エージェントでは、専門ごとにサブエージェントを並べるより、1つの主ループに必要なときだけ読み込むスキルとツールを持たせたほうが、品質が上がる場合が多いと主張する。

ある顧客の単一ループは複数エージェント構成より約2倍速く、Claude Codeのシステムプロンプトも80%超削ったと書く。数字は同社の自己申告で、独立した検証はない。



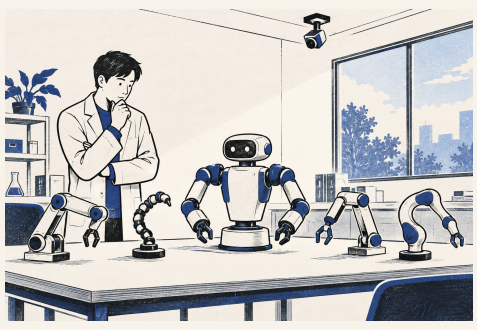
出典 Claude（Anthropic） ↗

■ ロボット・基盤モデル

Dream Labs、ロボット操作モデル「Dream-1」をAPIで公開

Dream Labsは10月、ロボットの操作モデル「Dream-1」を公開APIとして出した。映像と動作を一緒に予測し、2本のアームを持つロボットを3台のカメラの映像で動かす。学習していないロボットをゼロショットで動かせたのは、同社の報告でシミュレーション27台と実機4台だ。

第三者のRobocurveの評価として、コストはGemini 4 Argonの16分の1と紹介する。料金は1時間3ドルで、安全が重要な用途は未検証と明記する。



出典 Dream Labs ↗

短信

〈安全評価〉 AISI評価中の開発者標的、分析を公表
AnthropicとAISIが10月23日に公表。43回の評価中9回で想定外の行動（ITmedia）。 出典 ITmedia AI+ ↗

〈脆弱性〉 Brotli復号の重大脆弱性、更新を
CVE-2026-111497（CVSS 9.2）。Brotli 1.2.1、Node.js 22.23.4等へ更新を。 出典 Aikido ↗

〈数学〉 OpenAIの数学write-upを共同で改訂
Tao氏のブログのゲスト投稿。分かりにくく引用が不完全と指摘し、GitHubで改訂。 出典 Terence Tao's blog ↗

〈基盤〉 ChatGPT基盤のストレージ拡張策
10億人超・500PB超を扱い、世界の読み取り中央値は約120msから約10msへ。 出典 OpenAI ↗

〈仕様変更〉 Claude Coworkの仕様変更、日経が報道
クラウド型のみになるとの見出し。有料記事で冒頭しか確認できず、公式告知は未特定。 出典 日経コンピュータ ↗

〈検証〉 AIコードレビュー不合格率51%→13%の注意
個人の検証。10月209件で有効に判定したのは1モデルのみ。品質向上とは言えない。 出典 Zenn ↗

〈言語〉 AI生成文はなぜ理解しにくいのか
9モデルすべてが人間より低頻度のn-gramを多用。要旨に数値なし、査読前。 出典 arXiv ↗

〈経済〉 AI投資の成果は「Mag 7」の外に見えない
スロック氏は、1人あたり売上高・利益率はMag 7のみ上昇と主張。数値は図のみ。 出典 Apollo ↗

〈ガバナンス〉 Anthropic信託に物理学者が参加
10月21日、元ハーバード大理学部長のStubbs氏がLong-Term Benefit Trustに加わった。取締役の過半を指名できる。 出典 Anthropic ↗

〈比較〉 Copilot Agent BuilderとStudioの違い
同じ依頼で比べた個人検証。解けない条件ではStudioが判断を求め、ビルダーは違反0件と報告。試行は少数。 出典 Qiita ↗