テックデイリー
TECH DAILY
2026年10月31日（土）
第50号 朝刊

きょうの紙面 ▸ AI × 人の判断 ▸ セキュリティ × 開発ツール ▸ AI × 出典 ▸ 短信 8本

■ AI × 人の判断

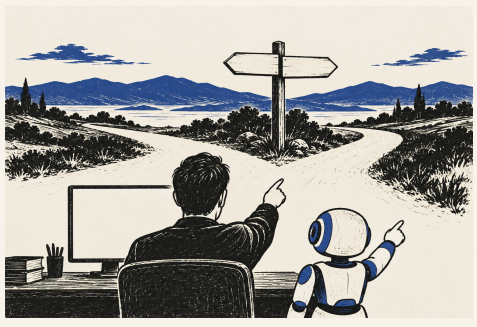
専門家50人、AIの助言の傾きに86%従う　Anthropicが実験

出典を挙げたのは15%　傾きは測定のため意図的に強めた自社研究

Anthropicは10月27日、AIエージェントの助言が専門家の判断をどこまで動かすかを調べた実験を公表した。因果推論の経験がある分析者61人のうち、エージェントを使った50人を解析した。課題は架空の農協の助言事業を拡大すべきかの分析で、4つの分析上の選択には、Claude Code（Claude Opus 4.8）の「傾き」をコイン投げで割り当て、本人には知らせなかった。

4つの選択の合計で、分析者がエージェントの傾きと同じ選択をしたのは86%（偶然なら約50%）だった。自分の意見を先に書いていた38件では、エージェントが反対すると60%が意見を変えた（賛成なら6%、95%CI 24〜82ポイント）。事後の説明でエージェントの論拠を使った人は77%で、出典として挙げたのは15%だった。

傾きは測定のため意図的に強めたもので、課題・分野・モデルは1つずつ。エージェント利用者の重大な誤りは50人中3人（6%）、利用しなかった11人では6人（55%）だが、2群は経験が違い直接は比べられない。自社研究である。



提案を受ける前に、自分の見立てを書いておく。

出典 Anthropic ↗

数字で見る

86%
助言の傾きと同じ選択

60%
先の意見を反対されて変更

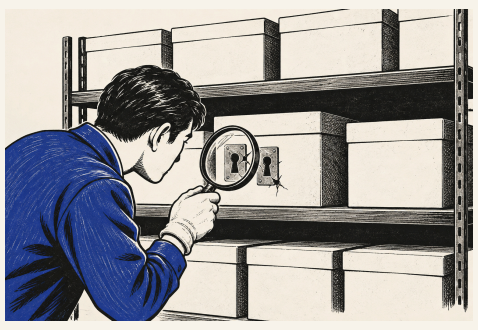
15%
論拠の出典に挙げた人

■ セキュリティ × 開発ツール

改ざん版Claude Code拡張 Cursorの市場で配布

Cursorは10月29日、同社のVS Code拡張マーケットプレイスで、Anthropic.claude-codeの改ざん版（2.1.312と2.1.313、WindowsとmacOS）が配布されたと公表した（30日に更新）。Anthropicが作ったものではなく、米国太平洋時間の29日午前2時27分ごろから午後1時35分ごろまで入手できた。

端末情報の送信、攻撃者のSSH鍵の登録、逆向きのSSHトンネルと常駐設定を試みる。攻撃者のサーバーは停止済みで、SSHの有効化に管理者権限が要るため多くの環境では失敗するが、鍵の登録と常駐は行われうる。該当時間に入れた人は点検が必要だ。セキュリティ会社Phorionも同じ版を確認している。



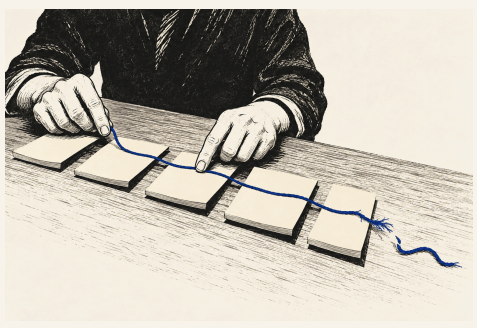
出典 Cursor ↗

■ AI × 出典

AIが示す統計、研究で裏付け 40%　Trakkrが1,285件調査

AI可視化サービスのTrakkrが、ChatGPT、Perplexity、Gemini、Claude、GoogleのAIによる概要に200問を投げ、引用された統計1,285件を最大5ページ先までたどった（10月28日）。同じ内容の研究に行き着いたのは40%（95%範囲34〜46%）、数字や条件が変わったのが8%、確認できないのが40%、行き先不明が11%だった。

引用先に数字自体が載っていたのは82%で、元の研究そのものだったのは21%にとどまる。ChatGPTが57%で最も高く、他の4つは38〜46%で順位は付けられない差とされる。独立した追試は未確認。医療の数字でも、引用先を2段たどり、対象人数と時期を確かめたい。



出典 Trakkr ↗

短信

〈医療AI〉 **EHR基盤モデルTRACER**
電子カルテの縦断データから診断を事前に予測する基盤モデル。複数施設での検出をうたう。査読前。 出典 arXiv ↗

〈OpenAI〉 **AI学習の許諾を共通信号に**
OpenAIがrobots.txtのAI学習許諾シグナルを尊重へ。IETFの作業に沿う方式で、実装は数か月以内。 出典 OpenAI ↗

〈OpenAI〉 **初の安全報告書を予告**
Q3の法執行機関への通報は200件超。初の安全報告書は2027年初頭に公開予定。 出典 OpenAI ↗

〈安全〉 **AI設計ツールの再現を検証**
AISIとSecureBio。論文全文からProteinMPNNを96.5%再現した例（最良値）。RFdiffusion3は未再現。 出典 ITmedia ↗

〈Google〉 **Gemini Notebookに教科書**
OpenStaxなど米印の教科書数百冊（医学含む）をソースに追加でき、質問回答や練習問題に使える。 出典 ITmedia ↗

〈Google〉 **Geminiでチャット内編集**
チャット内で生成したPDF・文書・スライドを直接プレビュー・編集できる機能を発表した。 出典 ITmedia ↗

〈OpenAI〉 **ChatGPT Proの上限を変更**
ChatGPT Proの100・500プランの上限を倍に。200プランの半減は撤回された。経緯まとめ。 出典 ITmedia ↗

〈国産LLM〉 **国産LLMに初の思考モデル**
国産LLM Sarashinaに初の思考モデル。ツール呼び出しやWeb検索の性能向上をうたい、API提供。 出典 ITmedia ↗