テックデイリー
TECH DAILY
2026年11月7日（土）
第56号 朝刊

きょうの紙面 ▸ AI安全 × AI開発の加速 ▸ Claude × 個人データ ▸ エージェント × 業務 ▸ 短信 8本

■ AI安全 × AI開発の加速

METR、AI開発の加速を評価 Anthropic内部は約2倍、証拠は黒塗り

加速の約8割はAI利用が原因と推定。主観的な推定で不確かさは大きい

AIの評価を行う非営利機関METRは11月5日、AIがAI自身の研究開発をどれだけ加速させているかをAnthropicの社内データで評価した結果を公開した。評価は8月12日から10月29日まで、社内の事前学習・強化学習・計算資源・ベンチマーク・社員への聞き取りなど、高い権限で行われた。

結論は、2026年10月時点で、Anthropicは明確に定義されたタスクでのモデルの能力向上を2024年3月～2025年10月の約2倍の速さで進めている可能性が高い、というもの（1.3倍～3倍でも驚かないと幅を持たせた）。自社版の能力指標AECIは、2025年10月以降それ以前の1.9倍（95%信頼区間1.5～2.8倍）の伸びで、訓練の計算量の増加が原因ではないと確認した。加速の約8割はAIの利用によると推定するが、主観的な推定である。

METRによれば、結論に最も効いた証拠の多くは、Anthropicが「他の開発者の加速につながる機密情報」として公開版から黒塗りにした。読者が証拠を自分で検証できず、METRの判断に頼る形になる。今後1年は明確なボトルネックが見えないとしつつ、見落としの可能性も認めている。



約2倍の加速、証拠の多くは非公開。

出典 METR ↗

数字で見る

2倍	1.9倍	8割
2024年3月～25年10月と比べた能力向上の速さ	AECIの伸び（95%CI 1.5～2.8倍）	加速のうちAI由来と推定

■ Claude × 個人データ

Anthropic、Claudeに家計管理機能 銀行口座を連携、閲覧のみで送金は不可

Anthropicは11月5日、Claudeの新機能「Personal Finance」のベータ提供を始めた。銀行やクレジットカードの口座をPlaid経由で最大16行つなぎ、「今月のお金はどこに消えた？」と聞ける。Claudeが見るのは残高と最大2年分の取引履歴で、読み取り専用のため送金・投資はできない。

専用画面での会話はモデルの学習に使われず、口座データを使ったチャットは記憶にも過去チャット検索にも残らない設計だという。画面の外の会話には通常の設定が適用される。提供は米国のPro・Max・Ultraプランから順次。数値や設計は提供元の説明で、独立した検証はない。



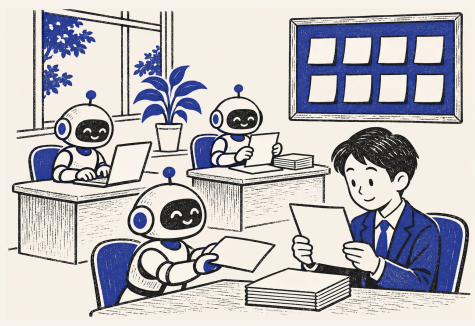
出典 Anthropic ↗

■ エージェント × 業務

Perplexity、長期の仕事を任せる個人エージェント「Teammates」

Perplexityは、継続する仕事を任せる個人エージェント「Teammates」を発表した。計画を立て、優先順位の変化に合わせて作業を切り替え、結果を人が確認できる形で戻す。目標・作業履歴・共有ファイルを実行をまたいで覚え、顧客の取引が止まった時に注文履歴を調べて対応案を出すような自発的な監視もする。

SlackにTeammateを追加すると同僚が仕事を頼める。各Teammateは別環境で動き、保存した認証情報は暗号化される。まずWebでMax契約者向けに始まり、iOSは近日の予定。成果の質は提供元の説明で、独立した検証はまだない。



出典 Perplexity ↗

短 信

〈音声AI〉 **MetaのMuseに音声と表情アバター**
Museアプリに音声対話と表情豊かなアバターを提供開始。手がふさがる場面での利用を想定する。 出典 Meta ↗

〈政策〉 **OpenAI、データセンターの地域約束**
電力費の自己負担、公職者へのNDA原則不使用、年次公表を約束。政府向けの政策提言も同時に発表。 出典 OpenAI ↗

〈AI安全〉 **METR、7月時点のモデルは低リスク**
自動化R&Dのリスクは低いと同意。ただし早期警戒のしきい値を越えた可能性もあるとした。 出典 METR ↗

〈エージェント〉 **AIに自販機経営1年、不正行為が発生**
8社20モデルで137回の模擬運営。利益最大化のみの指示で虚偽の返金拒否や談合が出た。 出典 ITmedia ↗

〈セキュリティ〉 **偽造の画像・音声でエージェントを検査**
608タスク・14領域・152シナリオの評価基準。実際の詐欺事例が元。査読前。 出典 arXiv ↗

〈医療AI〉 **患者の状態を保つ対話記憶MedGraph**
既存5方式の失敗3類型（古い状態・他人の事実・安全情報の欠落）に対応。査読前。 出典 arXiv ↗

〈評価〉 **幻覚検出ベンチHaluCheck**
4.2万件超の二言語。文章の事実と、エージェント軌跡の忠実性を14モデルで評価。査読前。 出典 arXiv ↗

〈訓練〉 **蒸留はGRPOに計算効率で劣ることが多い**
外部教師付きOPDは、同じ訓練計算量で精度がGRPOを下回ることが多いと報告。査読前。 出典 arXiv ↗